

# **Modelos de rating y scoring, introducción e importancia en la gestión del riesgo y el capital**

Daniel Fuentes

# INDICE

1. ¿Quién desarrolla los modelos?
2. Desarrollo de un modelo de *scoring*
3. Gestión de modelos de *scoring*
4. *Rating vs. scoring*



# 1 ¿Quién desarrolla los modelos?

# 1 ¿Quién desarrolla los modelos?

Equipos metodológicos especializados

## Equipos metodológicos especializados

En la mayoría de las entidades se tiene un equipo de metodología especializado, que es el responsable de la **definición, desarrollo y seguimiento de las metodologías y modelos de riesgos**

- **Conocimiento de las carteras y negocios** para los cuales los modelos se construyen, lo cual es relevante para garantizar una correcta interpretación de la información
- **Conocimiento de los sistemas y datos de la entidad.** Dado que la calidad de la información es fundamental para desarrollar un buen modelo, cuanto mayores conocimientos se tenga sobre aspectos como los sesgos de la información, la evolución histórica de la calidad de los datos, etc., más adecuado será el modelo desarrollado.
- **Conocimientos metodológicos** que eviten disponer de modelos falsamente predictivos
- **Conocimientos regulatorios** que aseguren que el modelo desarrollado es óptimo desde el punto de vista de gestión y cumple con los requerimientos normativos
- **Y obviamente experiencia en el desarrollo e implementación de modelos** anteriormente. En el desarrollo de un modelo siempre debe haber alguien con experiencia en el equipo que garantice no caer en los errores de alguien que lo haga por primera vez

# 1 ¿Quién desarrolla los modelos?

Gestores de cartera o de producto

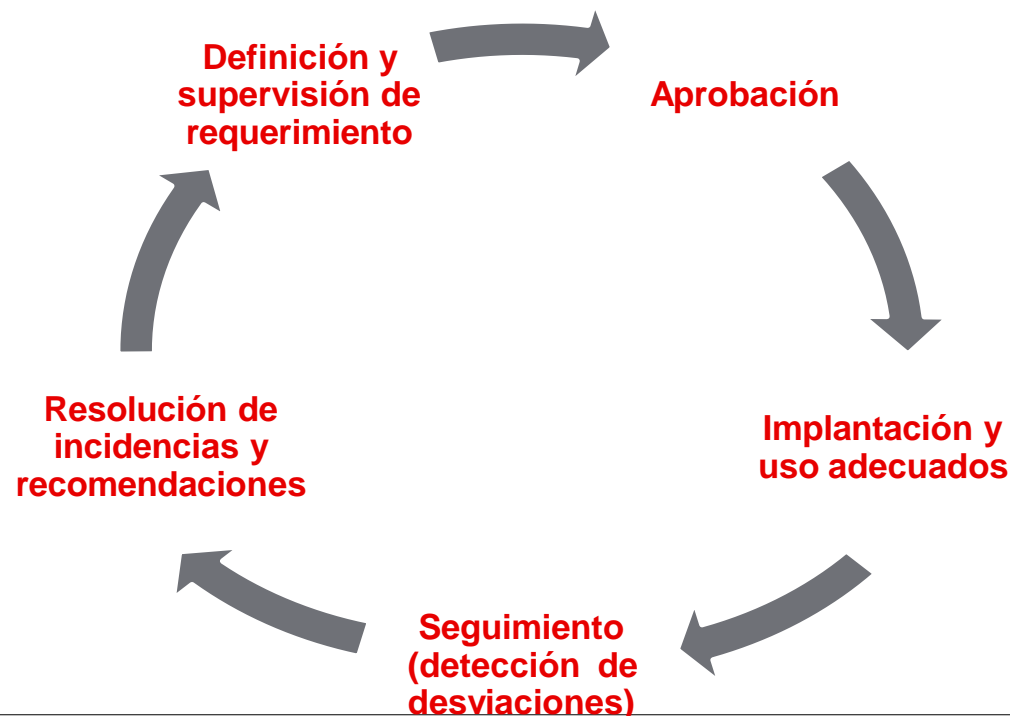
## Gestores de cartera o de producto

El gestor de cartera, como usuario responsable del modelo, ha de estar pendiente de todos los aspectos relacionados con el modelo y disponer de un alto conocimiento de la gestión con modelos. Son responsables de la correcta **implantación del modelo en las estrategias de la entidad así como del cumplimiento de los requerimientos normativos e internos**

El gestor de carteras debe tener un amplio conocimiento en los siguientes aspectos:

- **Carteras y negocios** para los que se construye el modelo
- **Definición de estrategias de crédito**
- **Procesos de admisión, seguimiento y recuperaciones**
- **Políticas y procedimientos de crédito de la entidad**
- **Sistemas de implementación de los modelos**
- **Aspectos legales y metodológicos**

El usuario del modelo por tanto debe identificar la necesidad de un modelo y asegurarse de que:



# 1 ¿Quién desarrolla los modelos?

## Equipos de validación de modelos

### Equipos de validación de modelos

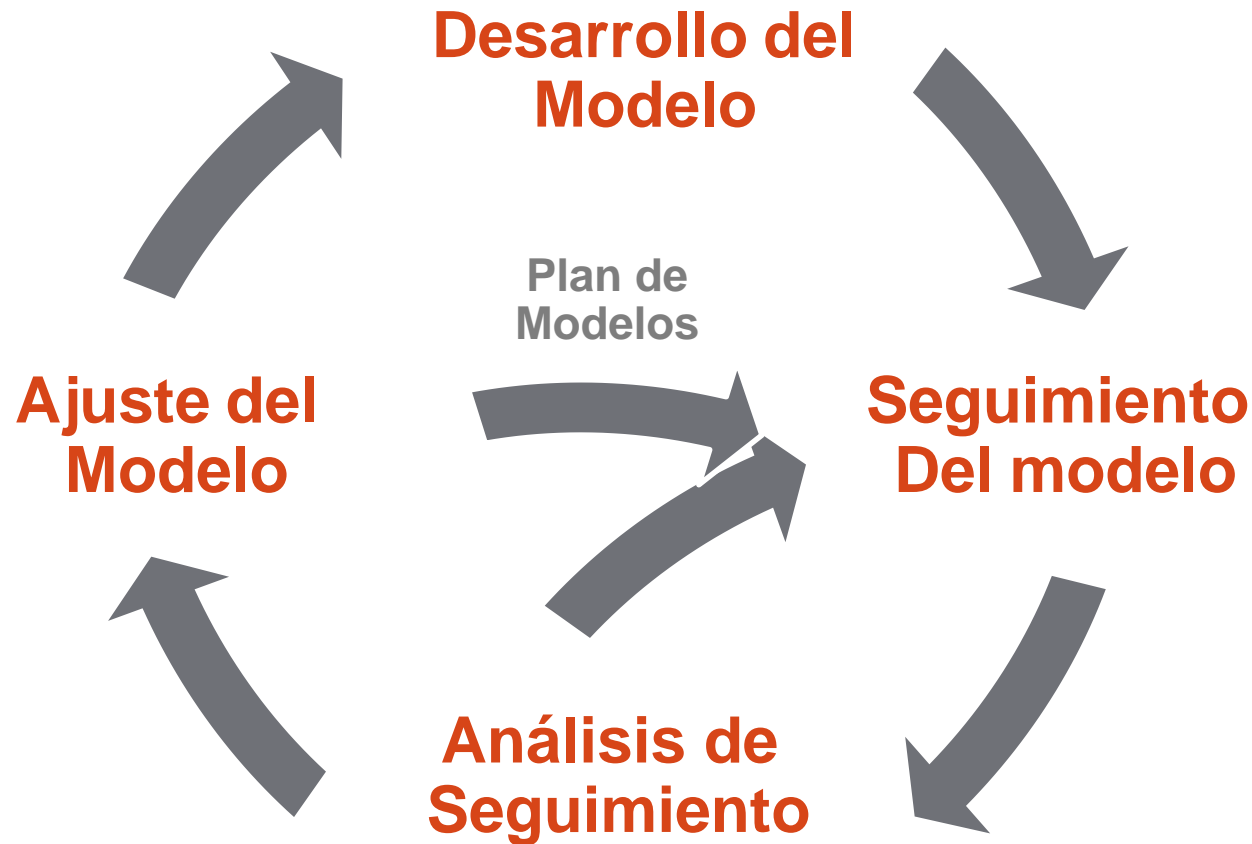
En las entidades financieras se dispone de equipos metodológicos que **validan la calidad de los modelos desarrollados, midiendo el riesgo de modelo implícito en cada uno de ellos**

- Los **conocimientos** necesarios en los equipos de validación son muy **similares a los de los equipos de desarrollo** de modelos. Aparte, deben conocer ampliamente los **requerimientos regulatorios e internos** en cuanto a la validación de modelos se refiere.
- Los informes de los equipos de Validación Interna son un input relevante en la opinión que realiza el regulador cuando revisa un modelo de riesgo.

# 1 ¿Quién desarrolla los modelos?

## Ciclo de vida de un modelo

Desarrolladores, Gestores de cartera y equipos de validación deben estar muy coordinados en los diferentes procesos del ciclo de vida de un modelo con el doble objetivo de tener el mejor modelo posible y que el proceso sea eficiente





## 2 Desarrollo de un modelo de *scoring*



## 2 Desarrollo de un modelo de *scoring*

### Planteamiento del problema




- **Número elevado de clientes**
- **Grupos de clientes y operativa homogénea**
- **Información estandarizada y estructurada**
- **Necesidad de estimar las consecuencias de cada decisión (planificar)**
  - Acertada: beneficio
  - Equivocada: coste
- **Maximizar la calidad de la decisión (estrategia)**
  - Control centralizado de las decisiones
  - Modificaciones con resultados predecibles
- **Minimizar el tiempo y coste de la decisión (automatizar)**

## 2 Desarrollo de un modelo de *scoring*

### El *scoring* como solución

Un *scoring* es un modelo matemático cuyo objetivo es ordenar la población en función de la probabilidad de que suceda un evento futuro




- Una herramienta
- Para medir la calidad de una decisión
- En base a los datos conocidos en el momento de la decisión
- Mediante criterios objetivos
  - Dada una solicitud de decisión, todos llegaríamos exactamente a la misma puntuación
  - Automatizable

## 2 Desarrollo de un modelo de *scoring*

### Valor añadido de un *scoring*

Un *scoring* es una herramienta objetiva y que de manera automática asigna una calidad crediticia



- **Objetivo**
- **Consistente**
- **Atribuye a cada puntuación una probabilidad de incumplimiento**
- **Facilita la automatización de las decisiones**
- **Clasifica solicitudes/clientes**
- **Permite un seguimiento detallado de su funcionamiento**

## 2 Desarrollo de un modelo de *scoring*

Qué no es un *scoring*

Para utilizar correctamente un *scoring* en la toma de decisiones se debe tener un conocimiento elevado de su alcance y limitaciones



- **Una máquina infalible.** No existe modelos 100% precisos; una PD del 50% significa 1 default / 1 no default
- **Una caja negra indescifrable.** El *scoring* debe recoger la manera de pensar de los analistas
- **La opinión subjetiva de un analista.** Las variables incluidas reflejan datos objetivos
- **El único culpable de las malas decisiones**
  - Datos malos = modelo malo
  - Es necesario interpretar lo que nos dice un *scoring*

## 2 Desarrollo de un modelo de *scoring*

### Limitaciones de un *scoring*

Los *scoring* son una buena solución cuando se dispone de poblaciones numerosas de las que poder extraer conclusiones estadísticas robustas

- No se debe aplicar en todas las decisiones de crédito
- Por ser de naturaleza estadística, no es aplicable en las siguientes circunstancias:
  - Situaciones en las que no se tiene experiencia
  - Operaciones atípicas por su perfil (ej. préstamo con 100% cash collateral)
  - Operaciones atípicas por el tipo de cliente (ej. Una operación de un volumen muy elevado en el segmento de empresas)



# 2 Desarrollo de un modelo de *scoring*

## Tipos de *scoring* por disponibilidad de datos



- **A medida:**

- Obtenido estadísticamente a partir de los datos propios de la entidad
- Proporciona la máxima potencia predictiva
- Sustituir cuando el seguimiento demuestre que su rendimiento se ha degradado

- **Genérico:**

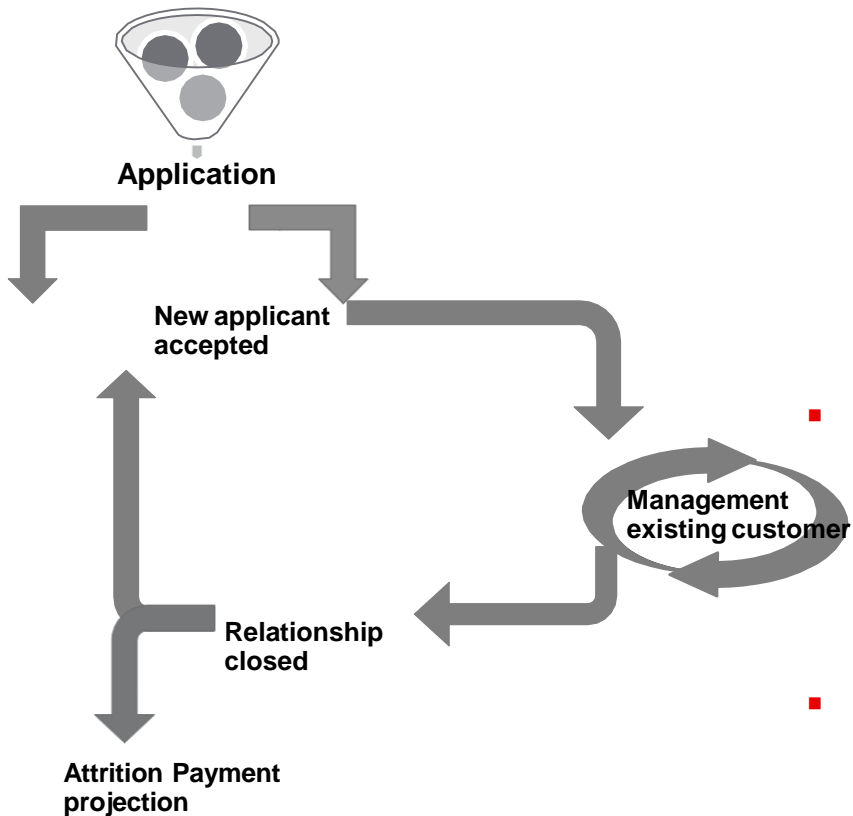
- No derivado de los datos propios de la entidad
- Sobre la cartera de varias entidades o en base a conocimiento de terceros
- Validar con una muestra mínima en cuanto esté disponible

- **Bureau:** resumen de todos los datos de un bureau de crédito



## 2 Desarrollo de un modelo de *scoring*

Tipos de *scoring* por el tipo de decisión a tomar



### ■ Admisión

- Evaluación de propuestas de crédito
- On-line
- En función de los datos conocidos en el momento de la decisión
- Reacción ante una petición del cliente

### ■ Comportamiento

- Evaluación continua de clientes a partir de sus datos de comportamiento
- Suele aplicarse en *batch* por iniciativa de la entidad

### ■ Recobro

- Modelo de comportamiento aplicado sólo a la cartera con impagos
- Trata de medir la probabilidad de cobro de la deuda

## 2 Desarrollo de un modelo de *scoring*

Tipos de *scoring* por el segmento / tipo de cliente



- Se buscan segmentos homogéneos que compartan datos comunes
  - Producto (hipotecas, tarjetas...)
  - Particulares
  - Autónomos
  - Pymes



## 2 Desarrollo de un modelo de *scoring*


Hipótesis de partida

El futuro será  
reflejo del pasado




«Estudia el pasado si  
quieres pronosticar el  
futuro» - Confucio

Un modelo de *scoring* es, a lo  
sumo, tan bueno como los datos  
sobre los que se construyó



## 2 Desarrollo de un modelo de *scoring*

Diagrama temporal – modelo de admisión



## 2 Desarrollo de un modelo de *scoring*

Un ejemplo de *scoring* de admisión

VARIABLES	CATEGORÍAS	PUNTOS
Operación de mayor antigüedad en la entidad	<36	80
	36<= valor< 120	87
	120<=	96
Límite en la tarjeta de crédito	< 1000	82
	1000<=	90
Tiempo trabajando	< 60	81
	60<= valor< 150	85
	150<=	92
LTV	Grupo 1	67
	Grupo 2	83
	Grupo 3	90
	Grupo 4	95
	Grupo 5	110
Modelo de alertas	< 50	62
	50<= valor< 55	73
	55<= valor< 58	84
	58<= valor< 60	94
	60<=	98
Finalidad del préstamo	GRUPO 1	60
	GRUPO 2	73
	GRUPO 3	80
	GRUPO 4	118

### Ventajas de un *scoring* como “tabla de puntuación”:

- Más fácil de interpretar, entender y utilizar
- Más fácil de explicar a un tercero ya sea el propio cliente o un supervisor
- Es una metodología estándar de mercado y no una caja negra
- Al ser un estándar permite disponer de herramientas tipo

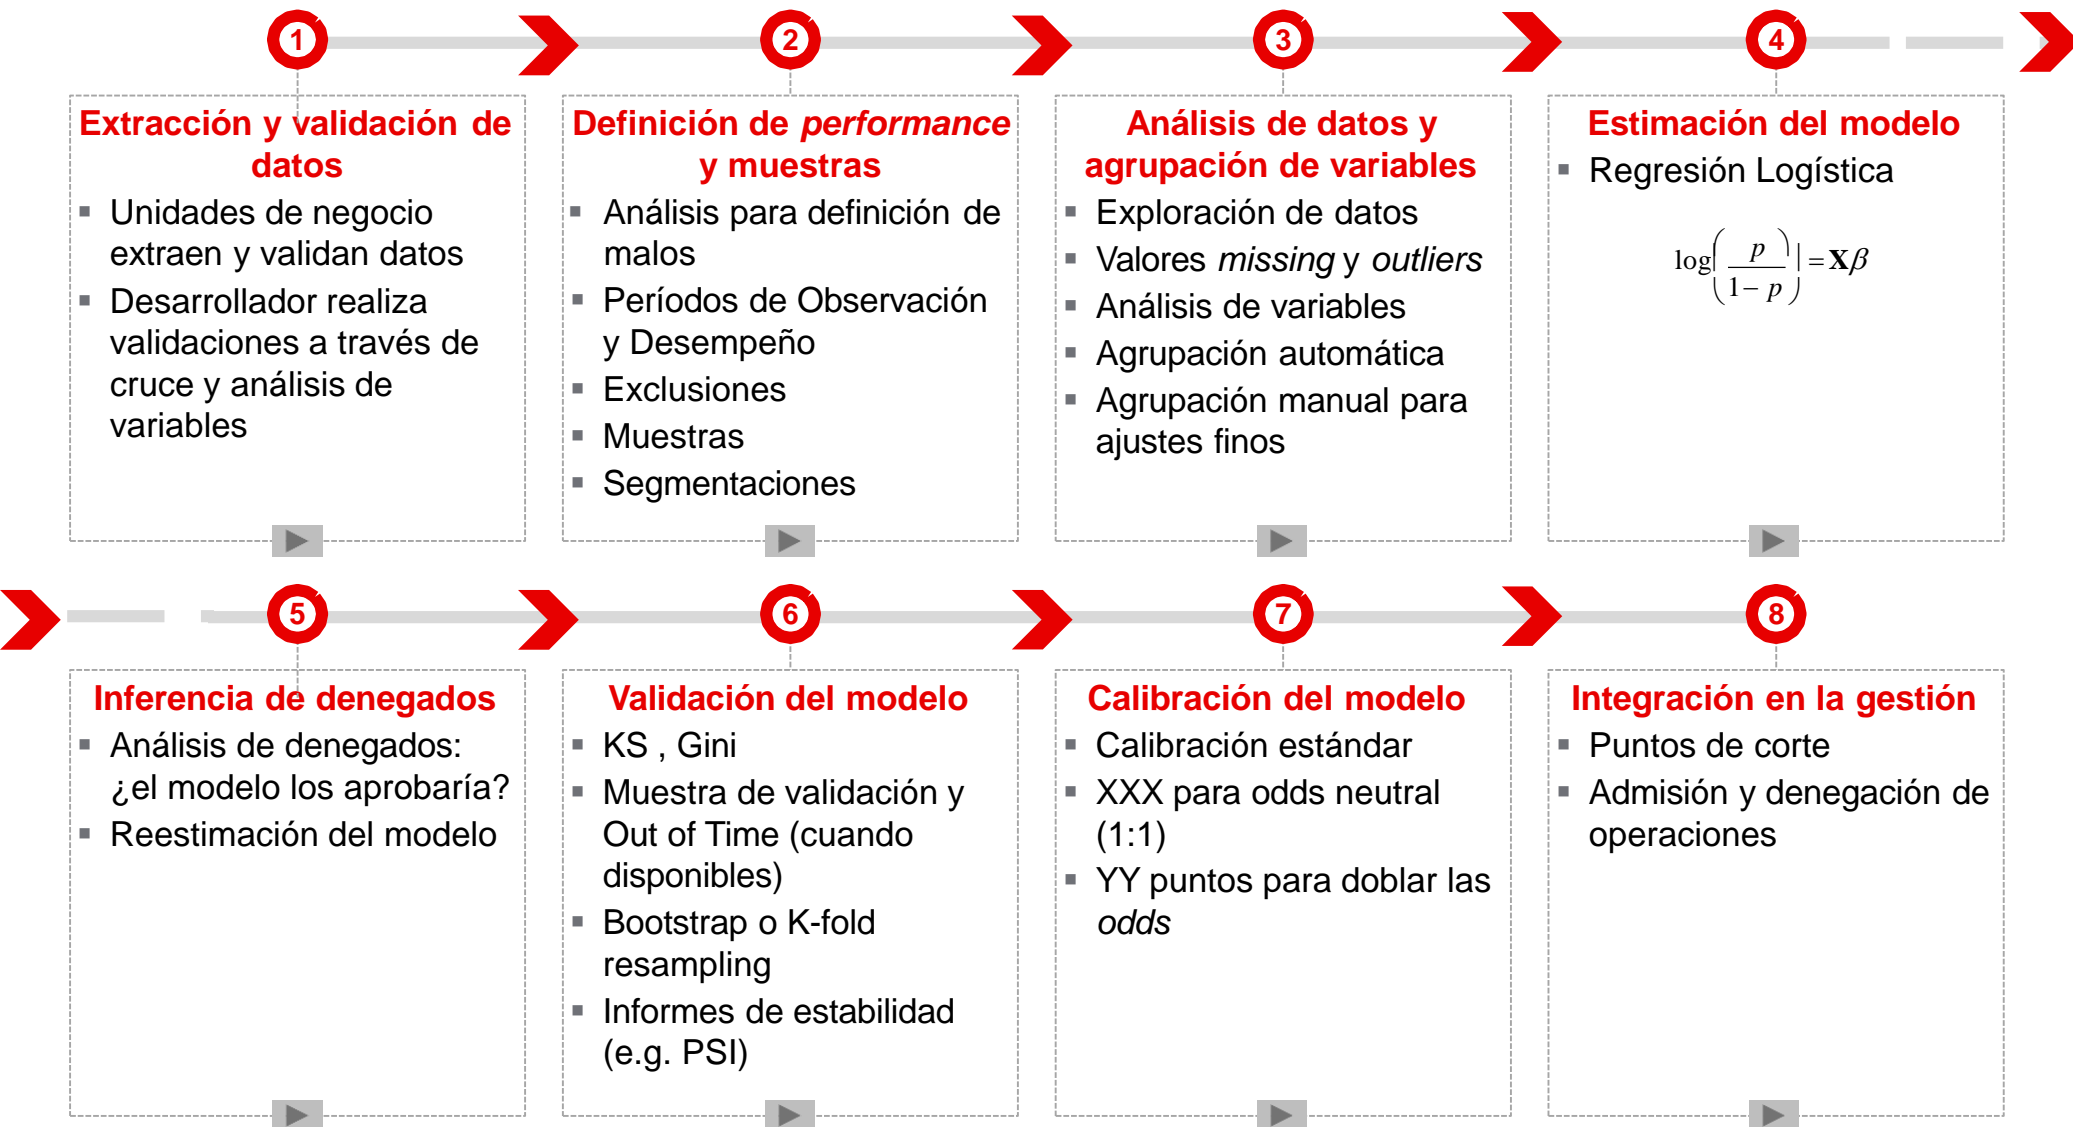


Recordatorio: un modelo de *scoring* tiene entre 8 y 14 variables habitualmente

Ejemplo ilustrativo de *scoring* no real

# 2 Desarrollo de un modelo de *scoring*

## Pasos para el desarrollo de un modelo de *scoring*



# 2 Desarrollo de un modelo de *scoring*

## 1. Extracción y validación de datos

### Elección de cartera



- Cartera de créditos homogénea
- Que compartan los mismos datos para tomar la decisión (al menos la mayoría)
- Que sea estable en el tiempo
- Con suficiente masa crítica para hacer viables los métodos estadísticos

**Es fundamental definir la población objetivo a la que se va a aplicar el modelo y a la que no. Las exclusiones pueden cambiar el universo al que se aplica el modelo y por tanto, pueden afectar a la discriminación y a los resultados esperados**



# 2 Desarrollo de un modelo de *scoring*

## 1. Extracción y validación de datos

### Extracción de datos



- Acotar la cartera
- Especificar la extracción de datos
- Los responsables de la extracción deben identificar los sistemas origen

### Exploración de datos

- No informados
- Inconsistencias
- Análisis descriptivo (frecuencias, máximos, mínimos, medias, ...)
- Evolución temporal de las variables



- **Corregir errores de extracción**
- **Descartar observaciones erróneas**
- **Recodificar de forma consistente**

**Es fundamental evitar sorpresas de última hora que impidan o dificulten implementar el modelo, como por ejemplo, que disponibilizar una variable del modelo sea muy costoso**

# 2 Desarrollo de un modelo de *scoring*

## 1. Extracción y validación de datos

### Dificultades habituales



- Tecnología tiene otras prioridades
  - Retrasos
- No todos los datos están almacenados
- Los datos están repartidos en muchas tablas
  - Más manipulación de datos
- Las solicitudes provienen de varios sistemas
  - Codificaciones inconsistentes

# 2 Desarrollo de un modelo de scoring

## 1. Extracción y validación de datos

### ¿Qué información es importante?

#### Modelos de Admisión

- **Características de la operación:** porcentaje de financiación (hipotecarios, autos), plazo, tasa de esfuerzo
- **Características del bien financiado:** edad (autos, hipotecas), tipo de bien (motocicleta, coches, etc.), valor, región
- **Características del Cliente**
  - **Particulares:** edad, estado civil, región donde vive, tiempo en la residencia, profesión, tiempo en la profesión / empleo, sexo (donde se permite utilizar la información)
  - **Pymes:** tiempo de empresa, sector de actividad, características de los socios
- **Informaciones de buró:** deuda activa en el mercado, deudas en retraso, cantidad de bancos, cantidad de consultas recientes al buró, comportamiento en deudas anteriores, puntuación, tipos de producto en el mercado
- **Informaciones de comportamiento del cliente:** tiempo como cliente, saldos, deudas, pasivos, puntuación de comportamiento

#### Modelos de Comportamiento / Recobro

- **Características de comportamiento del Cliente:**
  - Saldos y tendencias en 6, 9, 12 meses
  - Tiempo como cliente
  - Operaciones irregulares o morosas y comportamientos de pago anteriores
  - Debitos y créditos en 6, 9, 12 meses
  - Activos y pasivos en 6, 9, 12 meses
  - Días en crédito / débito
- **Informaciones de buró:** deuda activa en el mercado, deudas en retraso, cantidad de bancos, cantidad de consultas recientes al buró, comportamiento en deudas anteriores, puntuación de comportamiento, tipos de producto en el mercado



# 2 Desarrollo de un modelo de *scoring*

## 2. Definición de *performance* y muestras

### Clasifiquemos a las operaciones y clientes



- Malos
- Buenos
- ¿Indeterminados?
- No formalizados (*not taken up*)
- Denegados
- Excluidos

- **Es necesario separar “excluidos” y “denegados”.** Los primeros son operaciones o clientes para los cuales el modelo de puntuación no es aplicable en ningún caso mientras que para los “denegados” sí se aplica el modelo, incluso en los casos de denegación por reglas automáticas.
- **“Not taken-ups”** son operaciones aprobadas pero no formalizadas, normalmente por desistimiento del propio cliente. Estas operaciones pueden presentar comportamiento distinto de los denegados en el momento de hacer la Inferencia de Denegados.

# 2 Desarrollo de un modelo de *scoring*

## 2. Definición de *performance* y muestras

### Performance

#### Intuitivamente:

- Paga → Bueno
- No paga → Malo

#### Sin embargo...

- ...¿tan malo es el que lleva 30 días de impago como el que lleva 120?
- ...¿y el que entra y sale de impagados con frecuencia como el que no sale?

Index	Current Delinquency	Worst Delinquency	Nº of del.
1	0	0	0
2	0	1-90	1+
3	0	90+	1+
4	30	30	1
5	30	30+	2+
6	60	60	1
7	60	60	2+
8	60	90+	2+
9	90+	90+	1+

# 2 Desarrollo de un modelo de *scoring*

## 2. Definición de *performance* y muestras

Se ensayan varias definiciones de bueno / malo

Index	Current Delinquency	Worst Delinquency	Nº of del.
1	0	0	0
2	0	1-90	1+
3	0	90+	1+
4	30	30	1
5	30	30+	2+
6	60	60	1
7	60	60	2+
8	60	90+	2+
9	90+	90+	1+

Index	Current Delinquency	Worst Delinquency	Nº of del.
1	0	0	0
2	0	1-90	1+
3	0	90+	1+
4	30	30	1
5	30	30+	2+
6	60	60	1
7	60	60	2+
8	60	90+	2+
9	90+	90+	1+

# 2 Desarrollo de un modelo de *scoring*

## 2. Definición de *performance* y muestras

### Definición de malo



#### Intuitivamente:

- No paga → Malo

#### Los malos son definidos teniendo en consideración:


- La obtención de un volumen suficiente de casos que hagan viable el desarrollo de los modelos en todos los segmentos seleccionados (mínimo de 500 malos por segmento para *scorings*)
- La correlación con pase a fallidos (*scorings*)
- Sencillez en la definición, estabilidad de las variables utilizadas y significado para el negocio

**“Malo” y “Default” son cosas distintas – el concepto de Default utilizado para efectos de cálculo de capital regulatorio (90 días de retraso) no siempre es aplicable en el desarrollo de modelos de puntuación, a pesar de que en la medida de lo posible buscamos utilizar la misma definición.**

# 2 Desarrollo de un modelo de *scoring*

## 2. Definición de *performance* y muestras

### Ventana muestral




- La cartera debe representar las operaciones futuras
  - Cuanto más **reciente** mejor
- Para obtener un comportamiento de pago
  - Cuanto más **antigua** mejor
- ¿Cómo se compagina?
- Estabilización de la tasa de malos
  - Evitar buenos aparentes que van a ser malos un poco después
- **Procurar tomar 12/24 meses**
  - Especialmente en productos con alta estacionalidad
- Analizar también volúmenes y tasas de generación

# 2 Desarrollo de un modelo de *scoring*

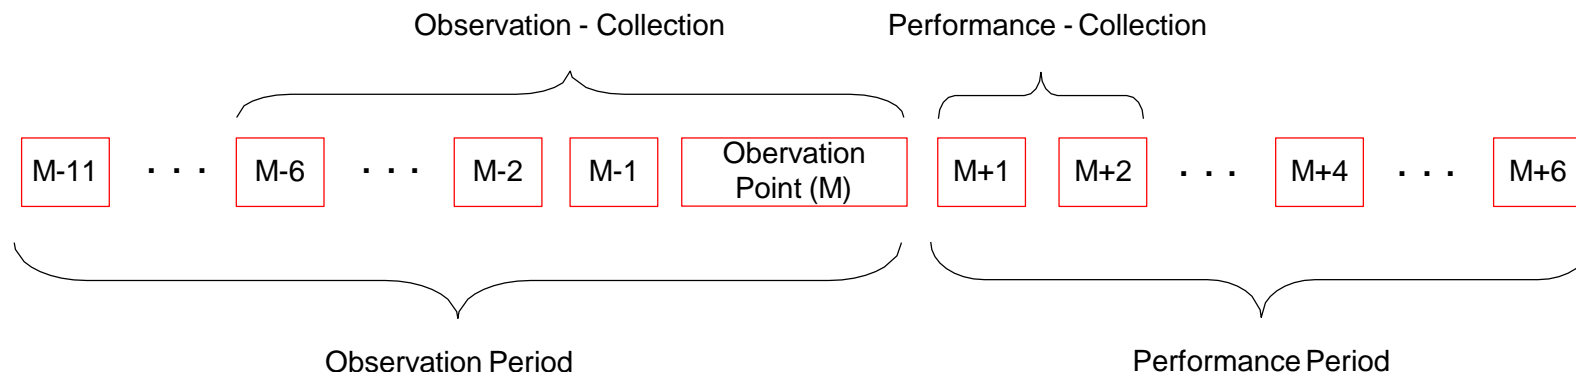
## 2. Definición de *performance* y muestras

### ¿Cuánto tiempo de histórico necesitamos?

- **Modelo de Admisión:** aproximadamente entre 24 y 36 meses



- **Modelo de Comportamiento:** aproximadamente entre 12 y 24 meses.




- **Recobro:** entre 6 y 8 meses

# 2 Desarrollo de un modelo de *scoring*

## 2. Definición de *performance* y muestras

### Muestreo

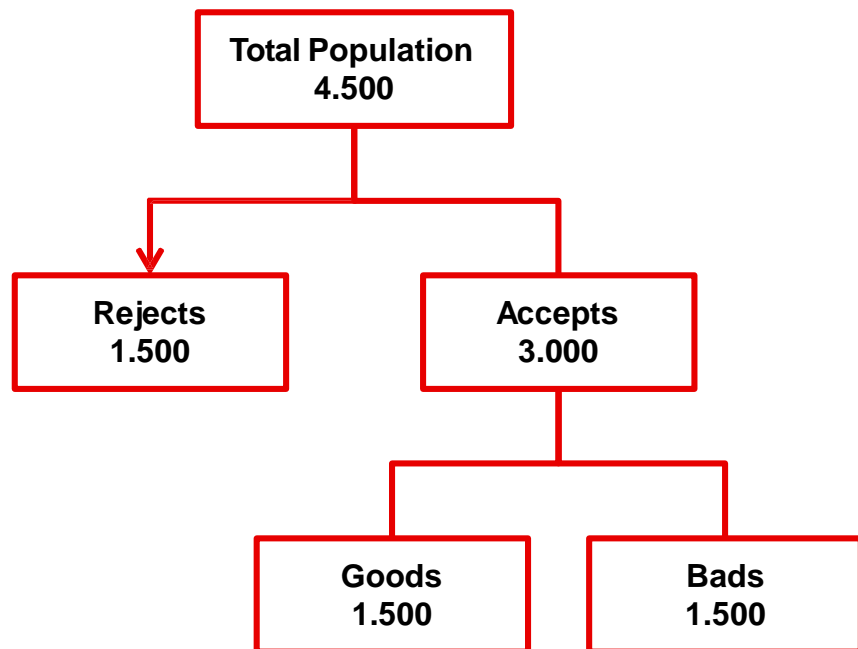


- A partir de un cierto número de observaciones, más solicitudes no añaden nada y añaden carga al programa de cálculo
- Los muestreos deben ser **aleatorios**
- **La riqueza estadística la da el número de operaciones de cada clase**
  - Mejor 1.000 buenos y 1.000 malos
  - Que 30.000 buenos y 300 malos
- Es frecuente incluir el mismo número de buenos que de malos

# 2 Desarrollo de un modelo de *scoring*

## 2. Definición de *performance* y muestras

### Factorización



- Hay que tener en cuenta el peso de buenos y malos

WEIGHTING			
	Population	Sample	Coefficients
Goods	G	g	$G*4.500/(g*N)$
Bads	B	b	$B*4.500/(b*N)$
Indeterminates	I	I	$I*4.500/(i*N)$
Accepts	A	a	
Rejects	R	r	$R*4.500/(r*N)$
Total	N	n	



# 2 Desarrollo de un modelo de *scoring*

## 2. Definición de *performance* y muestras

### Análisis de segmentación

- El Análisis de Segmentación **permite comparar modelos** contruidos sobre la población completa con modelos específicos desarrollados para segmentos seleccionados como “candidatos” por los gestores de riesgos

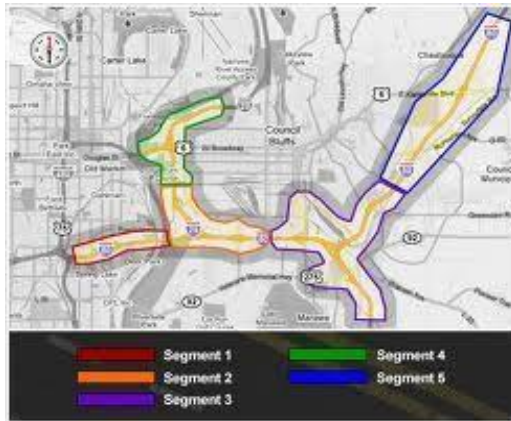


- No es complejo desarrollar códigos de análisis de segmentación que permitan comparar cuantos segmentos fuesen necesarios para decidir la mejor estrategia de segmentación a adoptar para cada desarrollo

# 2 Desarrollo de un modelo de *scoring*

## 2. Definición de *performance* y muestras

### ¿Cuándo segmentar más?



- No es una razón para segmentar:
  - Que un segmento sea más moroso que otro
- Sí es una razón para segmentar:
  - Que haya datos diferentes
  - Que el mismo dato apunte en dirección contraria en los dos segmentos



## 2 Desarrollo de un modelo de *scoring*

### 3. Análisis de datos y agrupación de variables

#### Tratamiento de valores missing



- Excluir los registros con datos missing. No es aconsejable porque normalmente se eliminaría un porcentaje muy alto de la muestra.
- Eliminar los registros o variables con un porcentaje o número elevado de valores missing.
- Incluir los missing en el scoring de manera diferenciada dando el tratamiento que se considere más adecuado, por ejemplo, penalizando la puntuación.
- Asignar un valor esperado al missing a través de técnicas estadísticas.

**Es necesario conocer el motivo por el que nos encontramos valores missing para darles un tratamiento adecuado.**

# 2 Desarrollo de un modelo de *scoring*

## 3. Análisis de datos y agrupación de variables

### Creación de nuevas variables



- **Obtener nuevas variables a partir de las dadas**
  - Edad = Fecha de solicitud – Fecha de nacimiento
  - Variables cruzadas (estado civil x edad)
  - Variables calculadas ( $\% \text{ entrada} = \text{Entrada} / \text{Precio del bien} \times 100$ )
- **Sólo cuando la variable nueva tiene sentido**
- Si no, el número de variables crece sin límite
- Acarrea **dificultades de implantación**
- Especialmente, los cruces
- En proyectos con muchas variables numéricas es un recurso habitual (ratios, tendencias...)

# 2 Desarrollo de un modelo de *scoring*

## 3. Análisis de datos y agrupación de variables

### Objetivos de la agrupación de variables



- Facilita el tratamiento de los outliers
- Homogeneiza el tratamiento de variables continuas y discretas
- Facilita el entendimiento del modelo de scoring al permitir asignar una puntuación a cada intervalo o grupo de atributos de las variables originales
- Dependencias no lineales pueden modelizarse de manera lineal
- Ayuda y facilita el análisis de la cartera

# 2 Desarrollo de un modelo de *scoring*

## 3. Análisis de datos y agrupación de variables

### Variables discretas y continuas



#### Variables discretas

- Sería ideal llegar a dar un peso diferente a cada categoría. Sin embargo, no es posible:
  - Porque tienen demasiadas categorías (valores)
  - O porque alguna categoría está poco representada
- Además plantea otros problemas
  - Dificultades de interpretación
  - Dificultades de implantación
- Agrupar categorías similares
  - Por calidad de la población
  - Por significado de la categoría

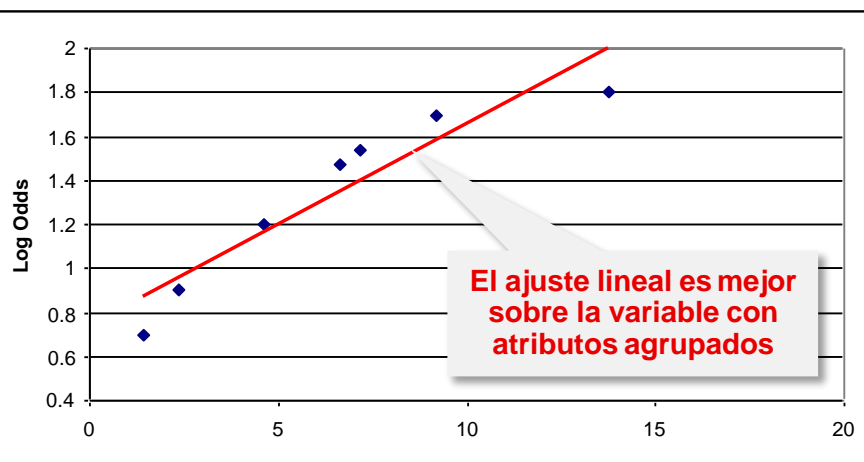
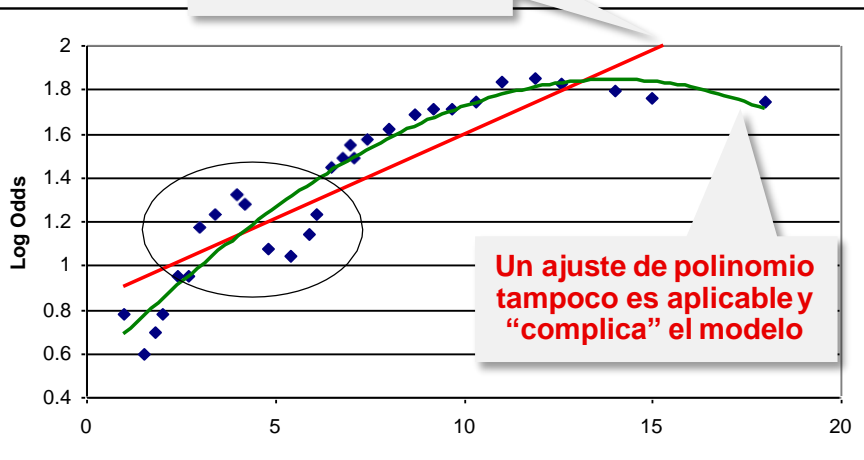
#### Variables continuas

- Efecto de la no linealidad
- El concepto es similar, pero se agrupan intervalos
- Buscando tendencias

# 2 Desarrollo de un modelo de *scoring*

## 3. Análisis de datos y agrupación de variables

El ajuste lineal no se aplica directamente a la variable




- La situación ideal es que la relación entre la variable explicativa y el logaritmo de los odds sea lineal
- Esto no siempre ocurre, lo que obligaría al desarrollador a encontrar transformaciones de la variable explicativa que optimicen la relación con los odds
- Las transformaciones no siempre se pueden aplicar y muchas veces no se quieren aplicar para no "complicar" el modelo de forma innecesaria
- Una alternativa es agrupar los atributos de cada variable para eliminar comportamientos de los odds que no se pueden explicar o bien que pueden ser consecuencia de problemas con la información (el modelo no puede ajustarse a los "ruidos")
- En algunas situaciones se quiere tratar algunos atributos de forma agrupada. Un ejemplo son regiones de un país con características próximas que deben ser puntuadas de forma agrupada dentro de un modelo


## 2 Desarrollo de un modelo de scoring

### 3. Análisis de datos y agrupación de variables

**Ejemplo: vivienda de residencia**



**Buenos de la muestra**




**Malos de la muestra**



## 2 Desarrollo de un modelo de scoring

### 3. Análisis de datos y agrupación de variables

**Ejemplo: incidencias en el pago**



## 2 Desarrollo de un modelo de *scoring*

### 3. Análisis de datos y agrupación de variables

#### ¿Es predictiva una variable?

VIVIENDA	Calidad B:M (odds)	% malos
Propiedad	22:1	4,35%
Alquiler	11:1	8,33%
Familiar	16:1	5,88%
Otros	9:1	10%

- Una variable es predictiva cuando ayuda a separar buenos de malos:
  - Si las calidades varían significativamente
  - Y las poblaciones de cada valor son suficientes

Ejemplo ilustrativo no real

## 2 Desarrollo de un modelo de *scoring*

### 3. Análisis de datos y agrupación de variables

#### ¿Cómo se mide si una variable es predictiva?



**La estadística nos proporciona varias opciones**

- Para medir la predictividad de un valor
- O de la variable en su conjunto

**Weight of Evidence WoE (*i*):**

discriminación del grupo *i* de la variable *x*

$$WoE_i = \ln \left( \frac{p_{bi}}{p_{mi}} \right)$$

**Information Value IV (*x*):**

discriminación de la variable *x*

$$IV_x = \sum_{i=1}^n (p_{bi} - p_{mi}) \ln \left( \frac{p_{bi}}{p_{mi}} \right)$$

*p<sub>bi</sub>*: porcentaje de operaciones buenas en el grupo *i*

*p<sub>mi</sub>*: porcentaje de operaciones malas en el grupo *i*

## 2 Desarrollo de un modelo de *scoring*

### 3. Análisis de datos y agrupación de variables

¿Cómo se mide si una variable es predictiva?


Edad 1er Titular	Num Malos	Num No Malos	Tasa de Malos	WOE
18 - 26 años	80	800	9,09%	-0,96
27 - 47 años	340	7.700	4,23%	-0,15
48 - 60 años	110	3.800	2,81%	0,28
Más de 60 años	45	3.000	1,48%	0,93
Missing	10	50	16,67%	-1,66
<b>Total</b>	<b>585</b>	<b>15.350</b>	<b>3,67%</b>	
IV	0,243			

Ejemplo ilustrativo no real

# 2 Desarrollo de un modelo de *scoring*

## 4. Estimación del modelo

### Modelización



- El análisis univariable señala las variables candidatas
- Una vez seleccionadas las candidatas
- ¿Qué variables entrarán definitivamente en el modelo?
- ¿Entran todas? No, no entran todas
- ¿Entran las más predictivas? Entran las que aporten algo que las otras no aporten
- ¿Con qué peso?

# 2 Desarrollo de un modelo de scoring

## 4. Estimación del modelo

### Correlación




**Algunas variables contienen información muy similar por lo que no es necesario incluir ambas en el modelo**


# 2 Desarrollo de un modelo de *scoring*

## 4. Estimación del modelo

### Correlación



Ejemplo con 3 variables:

- Lo habitual será que no entren las tres variables en el modelo
  - Si entran “Edad” y “Antigüedad Laboral”, la aportación de “Antigüedad en la vivienda” es marginal → No entra
- Existe más o menos **correlación entre todas las variables**
  - La **potencia predictiva de un modelo** es menor que la suma de las potencias de cada variable
  - La influencia de una variable en un modelo puede maximizarse o minimizarse
  - Los modelos no suelen tener más de **15 variables**
    - La aportación de variables adicionales no es significativa
    - Es preciso elegir entre variables disponibles
- 
- **Prioridad baja a variables que son:**
    - Caras
    - Difíciles de obtener
    - Susceptibles de cambiar
  - **Prioridad alta a las variables que son:**
    - Fáciles de obtener
    - Robustas

## 2 Desarrollo de un modelo de *scoring*

### 4. Estimación del modelo

#### Cálculo de los pesos



- Los algoritmos para el cálculo de los pesos son bien conocidos desde los años 30 y antes (en el mundo del riesgo, desde los 50)
  - Métodos de regresión
  - Análisis discriminante
  - Programación Lineal
  - Redes neuronales
  - Árboles de decisión,...
- Resultados similares independientemente de la técnica utilizada en el desarrollo
- Todas las técnicas **requieren calidad de datos**
- Modelos de éxito requieren más que “tecnología”.  
Objetivos adicionales:
  - Modelos de fácil interpretación
  - Modelos de fácil implantación
  - Modelos que posibilite el seguimiento/evaluación de las decisiones



# 2 Desarrollo de un modelo de scoring

## 4. Estimación del modelo

### Regresión logística

- Es la técnica estándar para desarrollo de modelos de scoring. Considerando  $p$  como la probabilidad de malos que se quiere estimar, el modelo de regresión logística se describe de la siguiente forma:

$$\log\left(\frac{p}{1-p}\right) = \mathbf{X}\beta$$

- Las principales ventajas de la regresión logística es que se trata de un modelo lineal generalizado para ajuste de una variable binaria, cuya estimación de parámetros ( $\beta$ ) es relativamente sencilla, y que permite obtener directamente una estimación de  $p$ :


$$p = \frac{1}{1 + \exp(-\mathbf{X}\beta)}$$

- Las variables explicativas ( $X$ ) pueden ser de distintos tipos: categóricas, ordinales o continuas, a pesar de que en el último caso también se puede transformar las variables continuas en categóricas a través de agrupaciones.
- Como comentado antes, para el modelo de regresión logística es suficiente la definición de apenas una categoría de la variable respuesta (malos), ya que la probabilidad de un “bueno” puede ser estimada fácilmente por  $1-p$ .
- Por lo anterior, no recomendamos la utilización de “indeterminados”, cuya utilización no agrega nada al modelo y genera trabajo adicional.

# 2 Desarrollo de un modelo de scoring

## 4. Estimación del modelo

### ¿Cómo es de bueno mi modelo?




### Índice K-S (Kolmogorov-Smirnor)

- Se define como la máxima distancia vertical entre:
  - La curva de distribución de los buenos
  - La curva de distribución de los malos
- Si las curvas coincidieran (clasificación aleatoria)
  - $K-S = 0\%$
- Si la clasificación fuera perfecta
  - $K-S = 100\%$

### Índice Gini

- El Gini y el KS están relacionados y los dos estadísticos son utilizados para medir la capacidad que tiene el modelo para “separar” entre buenos y malos

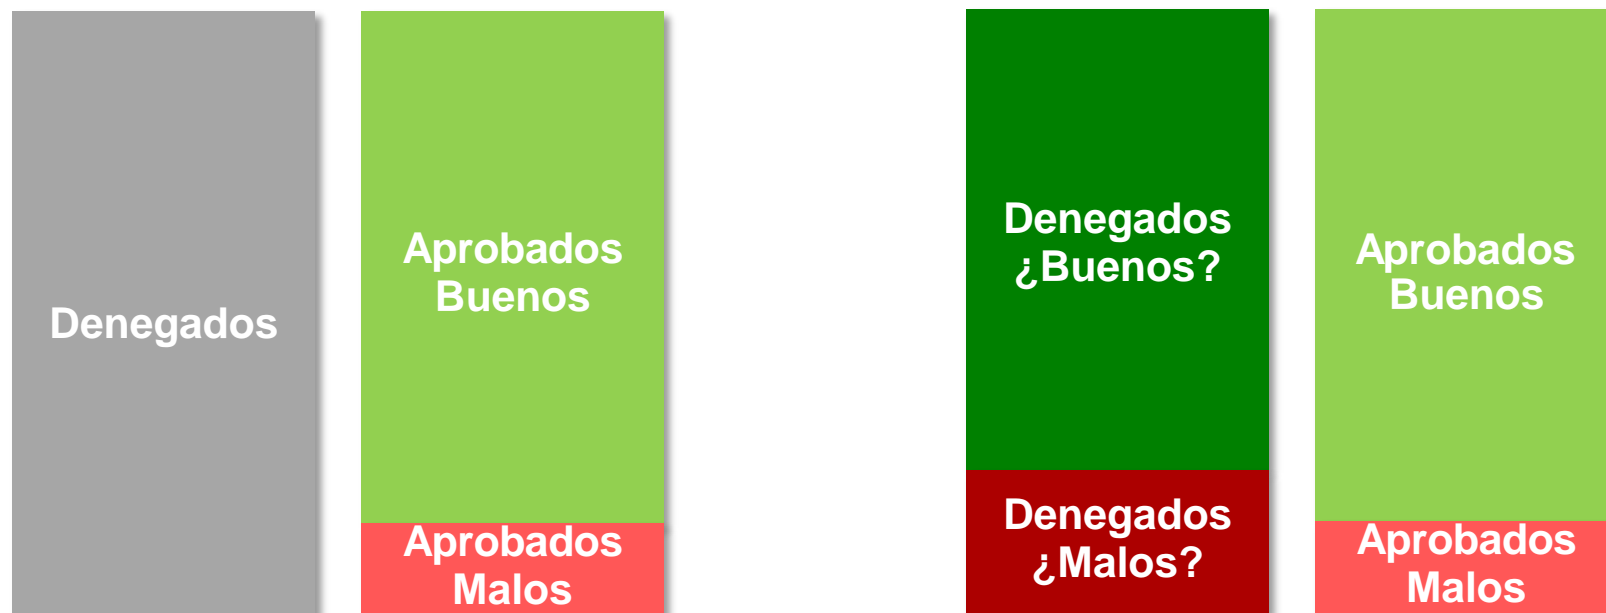


# 2 Desarrollo de un modelo de *scoring*

## 5. Inferencia de denegados

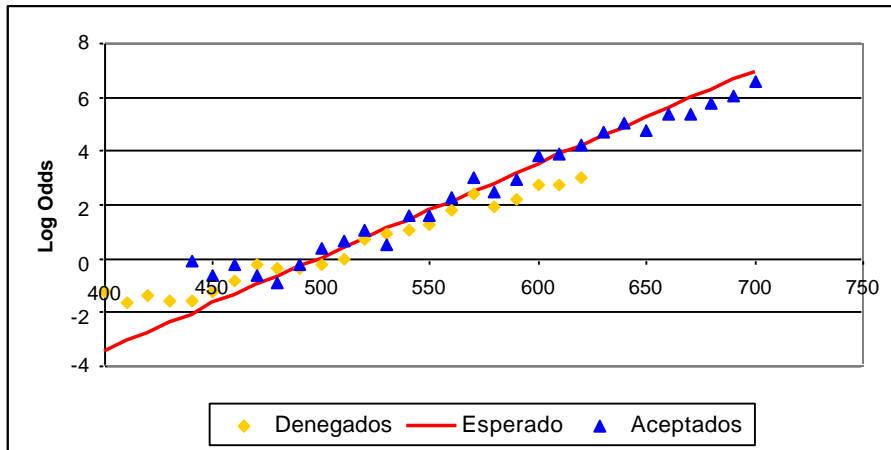
**La inferencia de denegados es la estimación del comportamiento del cliente denegado en caso de haberse aprobado**

- El desempeño de los clientes u operaciones denegadas es desconocido
- La alternativa es estimar qué comportamiento tendrían estas operaciones o clientes si hubiesen sido aprobados
- Se calcula la probabilidad de que el cliente se hubiese convertido en malo o bueno en caso de haberse aprobado



# 2 Desarrollo de un modelo de *scoring*

## 5. Inferencia de denegados



- **Los modelos de inferencia de denegados se deben desarrollar con toda la información disponible** sobre el cliente que permita obtener una mejor estimación de la probabilidad de malo, incluso información durante el propio periodo de desempeño del modelo, ya que el interés en este caso no es prever el futuro sino “prever el pasado”
- Una vez obtenida una probabilidad de malo, los denegados son duplicados en la muestra de desarrollo, una vez como malo y otra como bueno, cada una con un peso correspondiente a las respectivas probabilidades de malo o bueno

**No existe la fórmula perfecta para inferir el comportamiento de los denegados. Es necesario combinar algoritmos apropiados y sofisticados con experiencia y sentido común**

# 2 Desarrollo de un modelo de *scoring*

## 6. Validación del modelo

**Antes de aprobar un modelo e implantarlo es necesario realizar diferentes validaciones para garantizar su aplicabilidad**



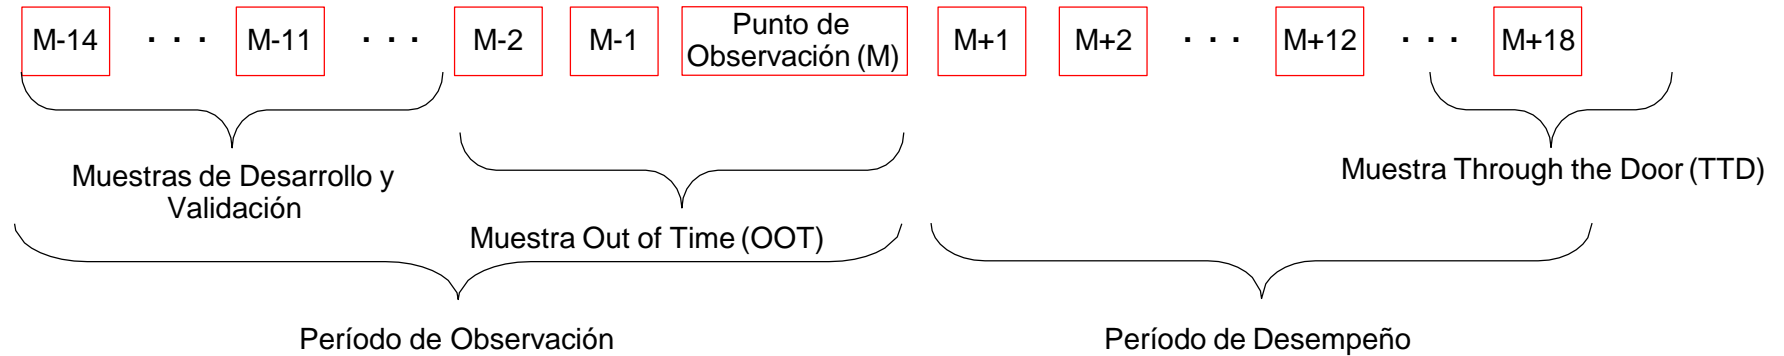
- **Riesgo de “sobreajuste” en la modelización**  
(ajustar tanto el modelo a la muestra que no sirva para el resto de la población)
  - Muestra de validación (*Hold Out*): procede de la misma ventana muestral (70/30)
  - Muestra de validación (*Out of Time*): procede de otra ventana muestral (normalmente más reciente)
- **Riesgo de que la población haya cambiado entre la muestra utilizada y la fecha de implantación**
  - Muestra reciente (*Through the Door*)

# 2 Desarrollo de un modelo de scoring

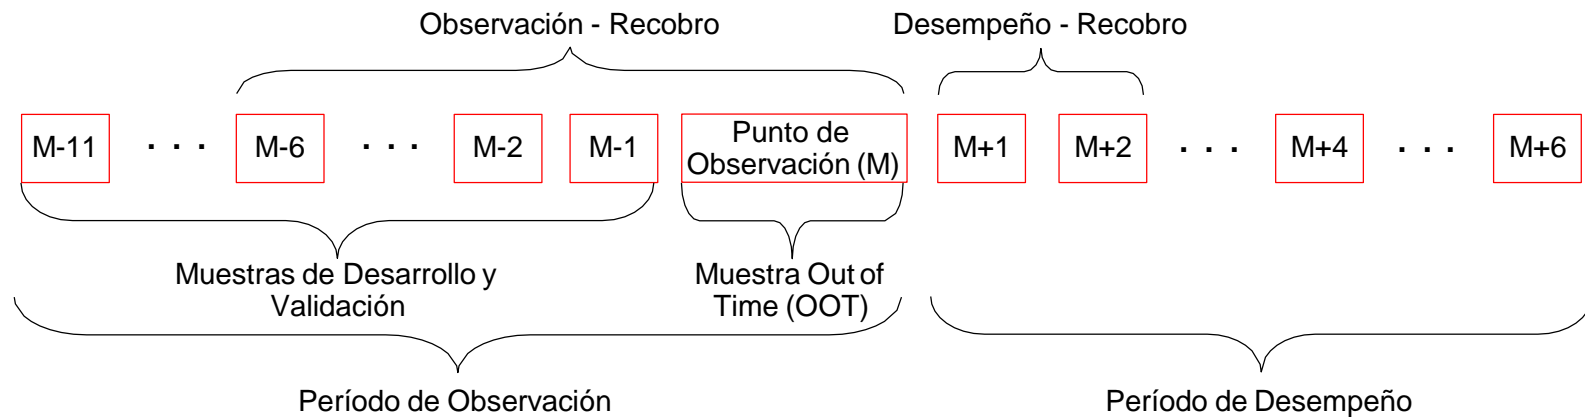
## 6. Validación del modelo

### Muestras de validación

- **Modelo de Admisión:** aproximadamente entre 24 y 36 meses




- **Modelo de Comportamiento:** aproximadamente entre 12 y 24 meses.



- **Recobro:** entre 6 y 8 meses

# 2 Desarrollo de un modelo de *scoring*

## 7. Calibración del modelo



**Score Calibrado = f (Score Inicial)**

XXX Puntos → Odds = 1

YY PDO → Puntos para doblar la odds

- **Los pesos obtenidos** mediante regresión logística, árboles, análisis discriminante, etc. son:
  - Poco intuitivos
  - Cosméticamente nada atractivos
  - No son comparables de un modelo a otro
- **Es necesario calibrar el modelo definitivo** de forma que
  - Manteniendo la relación entre puntos y la tasa de malos
  - Facilite la interpretación de cada peso
  - Facilite la definición de los puntos de corte
  - Y permita comparar distintos modelos (incluso obtenidos con distintas metodologías)


# 2 Desarrollo de un modelo de scoring

## 7. Calibración del modelo

### Ejemplo de calibración

**Score = 400 Odds = 1:1**  
**Por cada cliente malo hay**  
**1 cliente bueno**  
**Probabilidad de malo = 50%**

**Score = 500 Odds = 32:1**  
**Por cada cliente malo hay**  
**32 clientes buenos**  
**Probabilidad de Malo = 3%**





## 2 Desarrollo de un modelo de scoring

### 8. Integración en la gestión

¿y para el usuario?

### Tabla de Rendimiento

<i>Puntos</i>	<i>%Aceptación</i>	<i>%Malos</i>
...	...	...
<b>150</b>	<b>88.21%</b>	<b>10,03%</b>
155	87.37%	9,61%
160	86,49%	9,22%
165	85,67%	8,91%
170	84,99%	8,60%
...	...	...

<i>Puntos</i>	<i>%Aceptación</i>	<i>%Malos</i>
...	...	...
150	88.21%	10,03%
155	87.37%	9,61%
160	86,49%	9,22%
165	85,67%	8,91%
<b>170</b>	<b>84,99%</b>	<b>8,60%</b>
...	...	...

# 2 Desarrollo de un modelo de scoring

## 8. Integración en la gestión

### Puntos de corte – ejemplo de uso

Ejemplo ilustrativo no real

Score band	Development							Hold-out						
	Expected bad rate	#	# good	# bad	% / total	% approved	Observed bad rate	Expected bad rate	#	# good	# bad	% / total	% approved	Observed bad rate
000-570	30,66%	1.371	944	427	9,1%	100,0%	31,1%	30,66%	928	604	324	9,3%	100,0%	34,9%
571-578	20,13%	1.101	889	212	7,3%	90,9%	19,3%	20,13%	729	582	147	7,3%	90,7%	20,2%
579-586	15,96%	1.779	1.511	268	11,9%	83,5%	15,1%	15,96%	1.181	993	188	11,8%	83,4%	15,9%
587-594	12,30%	2.079	1.813	266	13,9%	71,7%	12,8%	12,30%	1.404	1.226	178	14,0%	71,6%	12,7%
595-601	9,58%	1.519	1.356	163	10,1%	57,8%	10,7%	9,58%	977	870	107	9,8%	57,6%	11,0%
602-612	7,40%	1.967	1.796	171	13,1%	47,7%	8,7%	7,40%	1.338	1.229	109	13,4%	47,8%	8,1%
613-623	5,31%	1.656	1.561	95	11,0%	34,6%	5,7%	5,31%	1.137	1.070	67	11,4%	34,4%	5,9%
624-636	3,37%	1.923	1.854	69	12,8%	23,5%	3,6%	3,37%	1.255	1.212	43	12,6%	23,1%	3,4%
637-999	1,83%	1.605	1.585	20	10,7%	10,7%	1,2%	1,83%	1.051	1.030	21	10,5%	10,5%	2,0%
<b>Total</b>	<b>11,03%</b>	<b>15.000</b>	<b>13.309</b>	<b>1.691</b>	<b>100,0%</b>		<b>11,3%</b>	<b>11,03%</b>	<b>10.000</b>	<b>8.816</b>	<b>1.184</b>	<b>100,0%</b>		<b>11,8%</b>

- Modelo de admisión con KS de 31%
- Observamos poca diferencia entre la tasa de malos esperada (Exp. BR) y la real (BR), tanto en la muestra de desarrollo como en la de validación (Hold-Out)
- La definición de puntos de corte depende de las características del negocio (tipo de operación, spreads, plazos etc). Estas características definen cual es la tasa de malos máxima soportada por cada negocio (break even). Suponiendo un “break even” de 11% en tasa de malos, una posible estrategia de decisión seria:
  - Denegar de forma automática los clientes con puntuación hasta 570 - aproximadamente 9% del total con una tasa de malos de 31%
  - Aprobar automáticamente los clientes con puntuación de 595 o más - aproximadamente 58% de aprobación automática con una tasa de malos máxima de aproximadamente 11%
  - Enviar para análisis manual los clientes entre 571 y 594 puntos – aproximadamente 33% del total

# 2 Desarrollo de un modelo de scoring

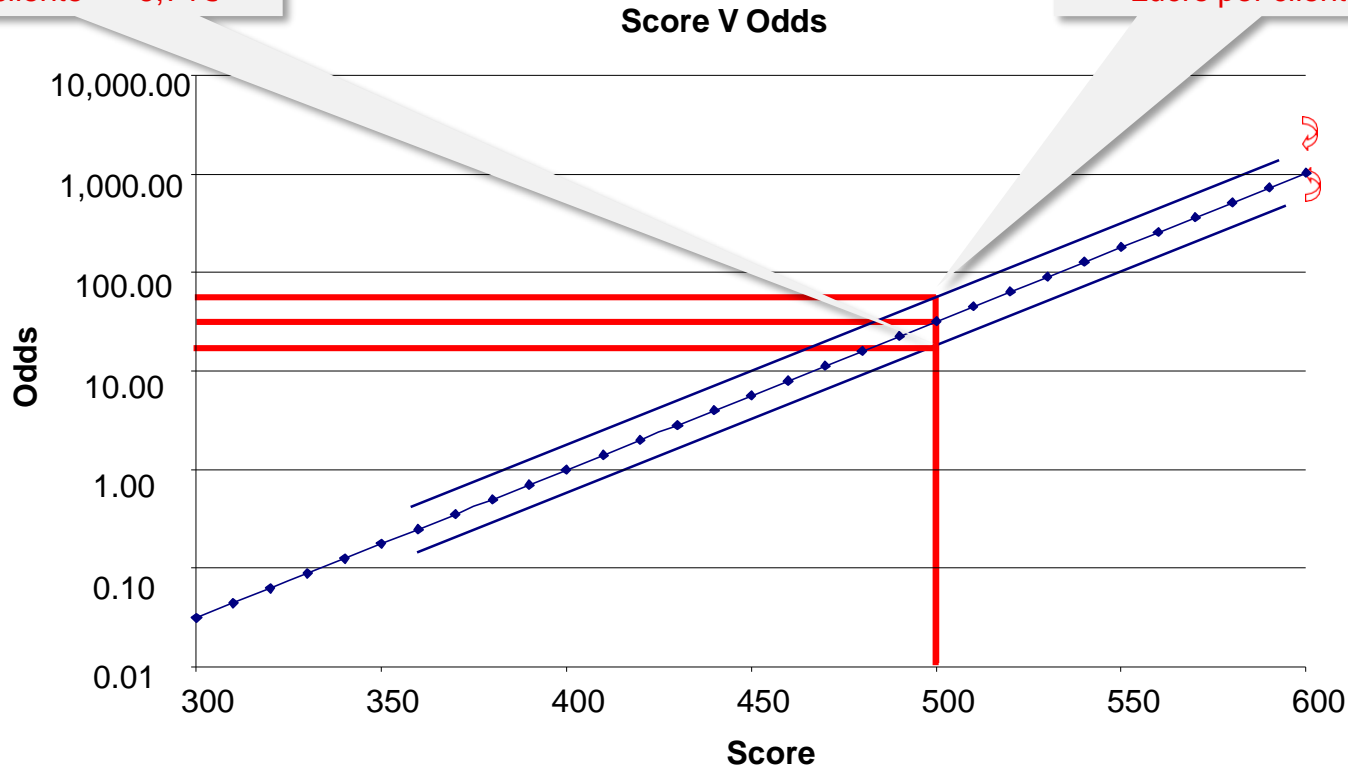
## 8. Integración en la gestión

### Importancia de la calibración para la integración del modelo

Si para cada cliente bueno ganamos 10€ y para cada malo perdemos 320€  
Break even odds = 32:1 (Score = 500)

Si los Odds en 500 puntos  
son en realidad 20:1  
Cliente Bueno =  $20 * 10 = 200€$   
Cliente Malo =  $1 * 320 = 320€$   
Lucro por cliente = - 5,71€

Si los Odds en 500 puntos  
son en realidad 50:1  
Cliente Bueno =  $50 * 10 = 500€$   
Cliente Malo =  $1 * 320 = 320€$   
Lucro por cliente = 3,53€





### 3 Gestión de modelos de *scoring*

# 3 Gestión de modelos de scoring

## Seguimiento

### Vigilancia continua

- Del funcionamiento del modelo
- De la calidad de la implantación
- Las decisiones tomadas, reglas de riesgo aplicadas y condiciones comerciales ofrecidas

### Objetivos

- Comprobar en qué áreas la predicción se ajusta a la realidad y en qué áreas se desvía
- Explicar las desviaciones
- Tomar las acciones adecuadas para corregirlas cuando corresponda

### ¿Cuándo realizar el seguimiento?

- Seguimiento continuo, aunque todo vaya bien
- Con una frecuencia determinada (trimestral / mensual)
- Desde el primer mes de implantación

### Implicaciones

- Mover puntos de corte
- Ajustar un modelo
- Etc.

# 3 Gestión de modelos de *scoring*

## Datos necesarios



- Aceptadas y denegadas
  - Todos los datos conocidos
    - Solicitud
    - Internos
    - Bureau
  - Del mes o de un periodo
- Impagados
  - Última situación
    - Histórico
    - Recobro
  - Cancelaciones anticipadas

# 3 Gestión de modelos de scoring

## Estabilidad

La hipótesis de que el **futuro** es un **reflejo del pasado** no es más que una **buena aproximación**

**Una población es estable si pasado el tiempo su distribución no ha variado. Por ejemplo, la distribución de los score es la misma.**


Los cambios en la distribución de la población pueden deberse a diferentes causas:

- **El perfil de nuestros clientes ha cambiado** (poco frecuente)
- **El producto de crédito ha cambiado** (cambios en la oferta)
- **Errores en la implantación** (se recogen / calculan mal algunos datos)

# 3 Gestión de modelos de scoring

## Estabilidad


### Ejemplo de un modelo estable vs. inestable



Population Stability Index (PSI) = 0,015



- La distribución de actual de clientes (*Through the Door* – TTD) está de acuerdo con la esperada en el desarrollo y el índice de estabilidad de la población (PSI) es muy bajo (inferior a 0,10)



PSI = 0,500




- El modelo presenta un cambio importante de la población en relación al esperado y el PSI es alto (superior al 0,25).



### 3 Gestión de modelos de *scoring*

#### Estabilidad

El mismo análisis a nivel modelo se lleva a cabo también para cada variable de cara a aislar aquellas con mayor desviación



# 3 Gestión de modelos de *scoring*

## Estabilidad

¿Qué implica inestabilidad en un modelo?

- Un cambio en la distribución de puntuación no significa necesariamente que el modelo de *scoring* ha dejado de funcionar.
- Sí puede indicar la necesidad de fijar un nuevo punto de corte o modificar los porcentajes estándar que representan la población objetivo de la Entidad





# 3 Gestión de modelos de scoring

## Desempeño

¿Continúa siendo bueno el modelo?

Es clave garantizar que el desempeño del modelo sigue siendo similar al obtenido en el desarrollo.




# 3 Gestión de modelos de scoring


## Desempeño

### Ejemplo de un modelo con desempeño bueno vs. malo

Gini de acuerdo con el esperado para este tipo de modelo



Gini por debajo de lo esperado para este tipo de modelo, con leve tendencia de baja




# 3 Gestión de modelos de scoring

## Rendimiento

Recordemos que un modelo mal calibrado puede estar significando un coste de oportunidad o un coste de crédito mayor de lo esperado




Buen ajuste




# 3 Gestión de modelos de scoring

## Rendimiento



# 3 Gestión de modelos de scoring


## Rendimiento



# 3 Gestión de modelos de scoring

## Rendimiento

El mismo análisis a nivel modelo se lleva a cabo también para cada variable de cara a aislar aquellas con mayor desviación



- **Comparación de la puntuación media**
  - Teórica y observada
  - Depende de la población en cada categoría
- **GINI teórico y observado**
  - Depende, además, de la %malos de cada categoría




# 3 Gestión de modelos de scoring


## Rendimiento

### Ejemplo de un modelo con rendimiento bueno vs. malo

La calibración necesitaría un pequeño ajuste, sin embargo los odds están bien alineados con el esperado






No presentan una tendencia lineal, con el actual alternándose por encima y debajo de lo esperado



# 3 Gestión de modelos de *scoring*

## Clasificación

En base a lo anterior, los modelos de puntuación se clasifican en 3 categorías con el objetivo de recomendar una acción

-  **Rojo.** Se recomienda un nuevo modelo
-  **Ámbar.** Se requiere alguna acción (calibración, ajuste, etc.)
-  **Verde.** No hay acciones recomendadas

Además del RAG<sup>1</sup> puede ser preciso recabar información adicional sobre el tipo de acción a llevar a cabo

# 3 Gestión de modelos de *scoring*

## Subpoblaciones

**Los análisis anteriores de estabilidad, predicción de % de malos, etc., pueden realizarse sobre distintas subpoblaciones**

- Territorios
- Objeto del préstamo
- Plazo
- Promociones
- Cliente nuevo / existente
- ...

# 3 Gestión de modelos de *scoring*

## Estacionalidad

**Es preciso analizar la evolución temporal de distintos factores**

- Número de solicitudes
- Tasas de aprobación
- Tasas de malos

**¿Hay variaciones importantes entre periodos?**

**¿Se pueden explicar?**

# 3 Gestión de modelos de scoring

## Búsqueda de nuevas variables discriminantes

¿Nos vamos a conformar con seguir lo que tenemos o queremos saber si se puede mejorar?

- No existentes durante el desarrollo
- Poco fiables en sí mismas
- Variables cruzadas
- Mal capturadas: ejemplo, antigüedad en el domicilio

	DEVELOPMENT SAMPLE		CURRENT SAMPLE	
	% POPULATON	% BADS	% POPULATON	% BADS
1 YEAR	5%	33%	9%	34%
3 YEARS	7%	20%	15%	22%
5 YEARS	9%	15%	15%	16%
7 YEARS	10%	11%	15%	10%
10 YEARS	12%	8%	17%	7%
20 YEARS	12%	5%	19%	5%
> 20 YEARS	5%	2%	9%	3%
NO INFO	40%	11%	1%	8%
<b>TOTAL</b>	<b>100%</b>	<b>11%</b>	<b>100%</b>	<b>12%</b>

# 3 Gestión de modelos de *scoring*

## Planes de acción

### Del análisis...

- Discriminación global
- ¿Variables aún discriminantes?
- ¿Ponderación correcta?
- ¿Variables fuera de la tabla a integrar?

### ... a la acción

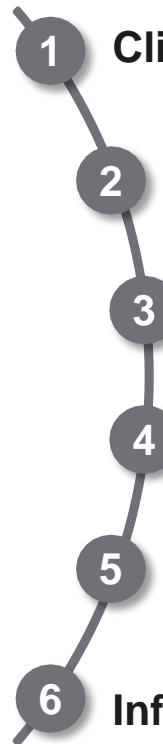
- Recalibrar el modelo
- Ajustar el modelo
- Nuevo desarrollo



## 4 *Rating vs. scoring*

## 4 **Rating vs. scoring**

¿Qué diferencia un *rating* y un *scoring*?

- 
- 1 **Cliente vs. operación**
  - 2 **Admisión vs. comportamiento**
  - 3 **Particulares vs. empresas**
  - 4 **Modelo basado en múltiples módulos**
  - 5 **Información cualitativa**
  - 6 **Información subjetiva**





Afi Escuela

---

© 2021 Afi Escuela. Todos los derechos reservados.